# **Project 3. DB Mining**

(Class: 데이터 관리 및 분석)

10조 나현수, 니키타 김, 박소정, 조현수

# **Requirement 1st**

#### Code

```
cursor.execute('USE %s;' % SCHEMA)
cursor.execute("""
#hot_gatherings.txt 파일의 내용을 담기 위한 새로운 테이블을 데이터베이스에 생성
sql hot_gatherings_list = """INSERT_INTO_Hot_Gatherings_List_VALUES (%s)"""
```

- 1) gatherings table에 hot\_gathering 여부를 나타내기 위한 column을 새로 추가
- 2) Hot\_gathering에 해당되면 1, 해당되지 않으면 0 할당

# **Requirement 1st**

#### Code

```
sql hot_gatherings list = """INSERT_INTO Hot_Gatherings_List_VALUES (%s)"""
       cursor.execute(sql_hot_gatherings_list, line_list)
```

- 1) Hot\_gatherings\_list txt file 을 연 후, 파일의 레코드를 Hot\_Gatherings\_List table에 저장
- 2) gatherings에 추가했던 hot\_gathering column을 update
- 3) txt파일의 레코드를 추가한 Hot\_Gatherings\_List 테이블에 gatherings 테이블의 id가 존재하면 1, 존재하지 않으면 0 할당

### **Requirement 1st**

#### Code



#### Code

- 1) gatherings table에서 가져올 수 있는 column들인 gathering\_id, hot\_gathering, age, description, average\_rating을 가져온 후, 이를 view1으로 설정
- 2) number\_of\_members를 select하기 위해, member\_gathering에 서 각 gathering\_id별로 member\_id를 count한 뒤 이를 view2로 설정
- 3) view1과 gathering\_id가 같은 조건으로 left join을 수행한 뒤 이를 view3로 지정
- 4) number\_of\_meetings를 select하기 위해, meetings 테이블에서 각 gathering\_id별로 개최한 오프라인 모임의 수를 count하여 view4
- 5) view3과 gathering\_id가 같은 조건에서 left join을 수행해 view5로 지정
- 6) number\_of\_recently\_joined\_members를 select하기 위해 각 그룹 별로 오늘과 가입 날짜 간의 년도 차이가 3보다 작은 멤버를 member\_gathering 테이블에서 count하여 view6으로 지정
- 7) view5와 gathering\_id가 같은 조건에서 left join을 수행한 후, gathering\_id로 ordering

#### Code

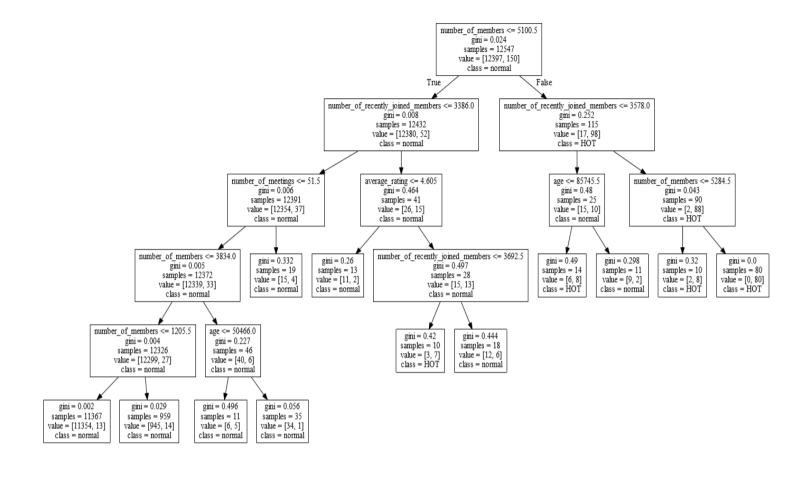
- 1) R2는 R1에서 반환 결과로부터 Hot Gathering 선정 기준에 대한 의사결정 나무를 생성하고자 한다.
- 2) 저장했던 .txt 파일을 pandas 모듈을 이용해 읽어 dataframe 형식으로 변환

#### Code

- 1) Label이 되는 class는 df형식으로 decision tree를 만들 수 없 기 때문에 array 형식으로 reshape
- 2) 필요한 칼럼만 남기고 모두 없앤 이후 txt 파일이 읽어 null 값이 'None'으로 읽히는 것을 모두 0으로 바꿈.
- 3) node impurity 측정 criterion을 gini로 설정한 tree를 생성하고, min\_samples\_leaf=10, max\_depth=5로 지정
- 4) 이 때 class는 hot\_gatherings가 아니면 normal로, hot gatherings에 해당되면 HOT으로 설정

#### **Results**

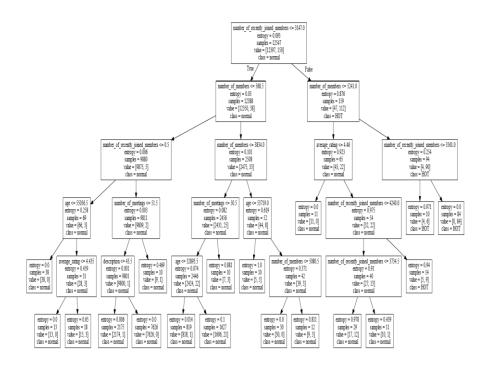
1) node impurity 측정방식으로 gini를 사용한 의사결정나무



#### **Results**

2) node impurity 측정방식으로 entropy를 사용한 의사결정나무

```
DI_entropy = tree.DecisionTreeClassifier(criterion='entropy', min_samples_leaf=10, max_depth=5)
graph_entropy = graphviz.Source(graph_entropy)
```



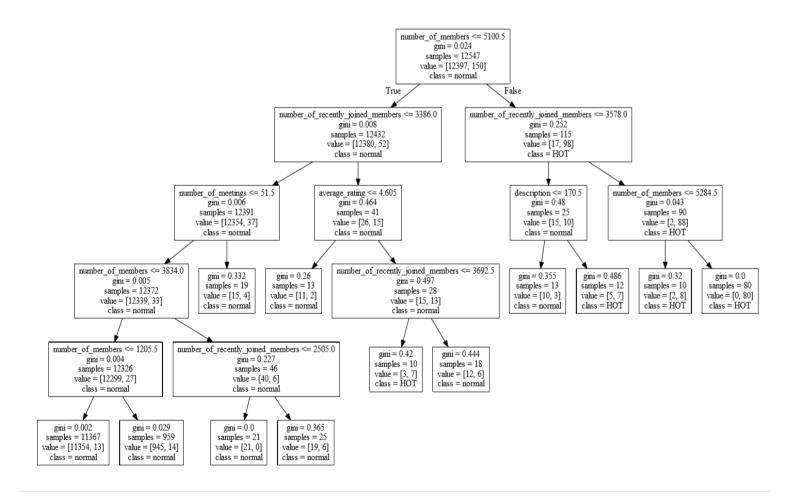
# **Requirement 3rd**

#### 설정 및 이유

- 새롭게 recently\_active와
   promptness\_active라는 column을 만들고 age column 삭제
- recently\_active : 오프라인 만남 정보가 최근에 업데이트 된 날짜 사이의 거리가 작을수록 recently active했으므로 hot\_gathering 여부에 영향
- promptness\_active : 오프라인 만남이 처음 정해진 날짜와 실제 모임 날짜 사이의 간격이 작을수록 신속성이 높아
   hot\_gathering 여부에 영향
- 신생 그룹이어도 최근 활발하면 hot\_gathering에 선정될 수 있다 판단해 age 삭제
- Node impurity : gini, entropy 모두 활용

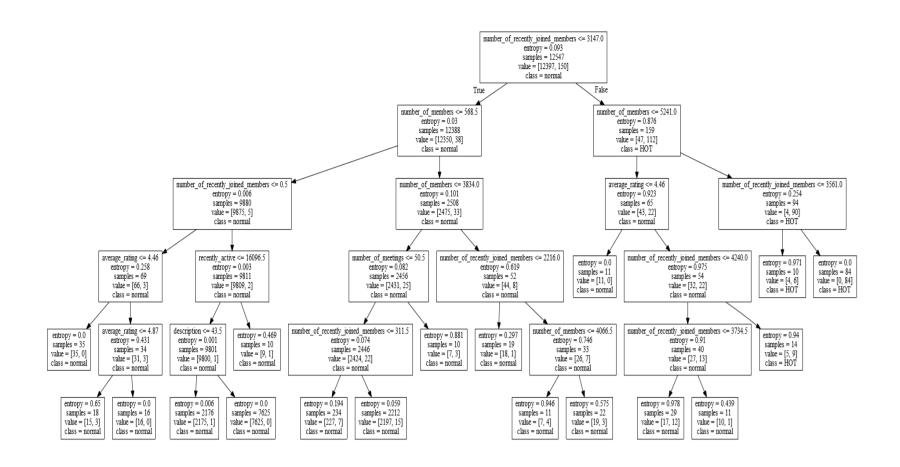
# Requirement 3rd

#### gini Method



# Requirement 3rd

#### entropy Method



# **Requirement 4th**

#### Code

```
part2():
   cnx = mysql.connector.connect(host=HOST, user=USER, password=PASSWORD)
   cursor = cnx.cursor()
   cursor.execute('SET GLOBAL innodb_buffer_pool_size=2*1024*1024*1024;')
   cursor.execute('USE %s;' % SCHEMA)
   cursor.execute('DROP VIEW IF EXISTS maybe_NY_gatherings;')
  cursor.execute('DROP VIEW IF EXISTS NY_gatherings;')
 # TODO: REQUIREMENT 4. WRITE MYSOL QUERY IN EXECUTE FUNCTIONS BELOW
 cursor.execute('''
    CREATE OR REPLACE VIEW M
    FROM members
# Gatherings that have 99% of members live in NY
# (SUM(CASE WHEN city_id = 10001 THEN 1 ELSE 0 END)) Counts number of people who live in NY
cursor.execute('''
   FROM member_gathering, members
   WHERE member_gathering.member_id = members.id
  GROUP BY gathering_id
  HAVING (SUM(CASE WHEN city_id = 10001 THEN 1 ELSE 0 END)) >= (COUNT(*) * 0.99)
```

- 1) 뉴욕 주의 뉴욕 시에서 활동하는 사용자들이 활동하는 그룹들 사이 연관 분석
- 2) 뉴욕에 살고 있는 가입자를 대상으로 수행
- 3) 구성원 중 99% 이상이 NY 출신인 Gathering을 선별하는 View 99\_NY 생성

# **Requirement 4th**

#### Code

```
# Gatherings and members 99% NY
cursor.execute(''
   CREATE VIEW maybe_NY_gatherings
   AS SELECT member_gathering.gathering_id AS gathering_id, member_id
   FROM 99_NY, member_gathering
   WHERE 99_NY.gathering_id = member_gathering.gathering_id
cursor.execute('''
   CREATE OR REPLACE VIEW 100_NY
   AS SELECT gathering_id as gathering_id
   FROM maybe_NY_gatherings
   LEFT JOIN M ON maybe_NY_gatherings.member_id = M.id
   GROUP BY gathering_id
   HAVING ((SUM(CASE WHEN city_id = 10001 THEN 1 ELSE 0 END)) = (COUNT(*)))
# Gatherings and members of 100% NY
cursor.execute(''
   CREATE VIEW NY_gatherings
   AS SELECT member_gathering.gathering_id AS gathering_id, member_id
   FROM 100_NY, member_gathering
   WHERE 100_NY.gathering_id = member_gathering.gathering_id
```

- 1) 구성원 중 99% 이상이 NY 출신인 Gathering의 gathering\_id, member\_id를 SELECT
- 2) 구성원 중 100%가 NY 출신인 Gathering을 선별하는 View 100 NY 생성
- 3) 구성원 중 100%가 NY 출신인 Gathering을 선별하는 NY\_gathering 생성

# **Requirement 5th**

#### Code

```
cursor.execute('''
     SELECT DISTINCT gathering_id
     FROM NY_gatherings
 gathering_id = cursor.fetchall()
 select_columns = ''
  or dot in gathering_id:
    select_columns = select_columns + "max(IF(gathering_id='{0}',1,0)) as '{1}',".format(dot[0], dot[0])
select_columns = select_columns[:-1]
  # Make Horizontal DataFrame
 cursor.execute('''
    SELECT member_id, ''' + select_columns + '''
    GROUP BY member id
 # Save it as pandas
df = pd.DataFrame(cursor.fetchall())
df.columns = cursor.column_names
df = df.set_index('member_id')
print(df)
 cnx.close()
 cursor.close()
```

### **Explanation**

- 1) R5는 NY\_gatherings을 horizontal table로 만들고 pandas의 DataFrame으로 저장하는 쿼리
- 2)row index는 member\_id로 GROUP BY
- 3)DataFrame으로 저장하는 과정에서 member\_id를 index로 선언

#### **Results**

	10010442	10015542	10052602	 9798532	9829012	9849892
member_id						
13355089	0	0	0	 0	0	0
13355180	0	0	0	 0	0	0
13355330	0	0	0	 0	0	0
13355433	0	0	0	 0	0	0
13355953	0	0	0	 0	0	0
13349444	0	0	0	 0	0	0
13349947	0	0	0	 0	0	0
13352617	0	0	0	 0	0	0
13352740	0	0	0	 0	0	0
13352770	0	0	0	 0	0	0

# **Requirement 6th**

#### Code

### **Explanation**

- 1) frequent itemset을 만들고 연관분석을 수행하는 쿼리
- 2) min\_support는 0.0025로 support가 0.0025이상인 itemset을 frequent itemset으로 정의
- 3) lift가 0.5이상인 경우 association rule이라고 보고 Results를 출력

#### **Results**

,antecedents,consequents,antecedent support,consequent support,support,confidence,lift,leverage,conviction